Actividad Individual | Código de experimentación base con MLflow

Daniel Ruán Aguilar

Matrícula: A01731921

Curso: TC5061

Repositorio con la actividad:

https://github.com/DaniRuan/TC5061-MLOps/tree/main/TC5061_Experimentacion_MLFlow_RuanDaniel

Objetivo y metodología

El notebook de exploración fue migrado a un script ejecutable organizado en funciones para cargar y validar los datos, preparar la partición, construir el pipeline, entrenar el modelo, evaluar sus resultados y registrar la ejecución en MLflow. El script utiliza argparse para exponer C, solver, máximo de iteraciones, tolerancia, semilla, tamaño de prueba, nombre del experimento y nombre de la corrida. Cada ejecución registra parámetros, accuracy, precision, recall, F1-score, ROC AUC, artefactos de evaluación y el pipeline entrenado. Todas las configuraciones se agruparon bajo el experimento TC5061_Experimentacion_LogisticRegression.

Ejecución por defecto

```
python src/train.py
```

Mejor configuración

```
python src/train.py --C 0.1 --solver lbfgs --max-iter 1000 --tol
0.0001 --random-state 42 --run-name C01_lbfgs
```

Interfaz de MLflow

```
mlflow server --port 5000 --backend-store-uri sqlite:///mlflow.db
```

Dirección local

```
http://127.0.0.1:5000
```

Análisis de resultados

Se ejecutaron cinco configuraciones distintas de regresión logística dentro del experimento TC5061_Experimentacion_LogisticRegression. Para permitir una comparación controlada, las corridas utilizaron la misma semilla aleatoria, random_state=42, una partición estratificada con 20% de datos de prueba y el mismo pipeline compuesto por StandardScaler y LogisticRegression. En cada ejecución se registraron en MLflow los hiperparámetros, cinco métricas, el modelo y tres artefactos de evaluación.

La mejor configuración fue C01_lbfgs, con C=0.1, solver=lbfgs, max_iter=1000 y tol=0.0001. Esta corrida obtuvo accuracy de 0.9825, precision de 1.0000, recall de 0.9524, F1-score de 0.9756 y ROC AUC de 0.9977. La matriz de confusión presentó 72 casos benignos y 40 malignos correctamente clasificados, ningún falso positivo y dos falsos negativos. La selección se sustenta principalmente en recall, porque en este problema un falso negativo representa un tumor maligno

clasificado como benigno. Entre las tres configuraciones que alcanzaron recall de 0.9524, C01_lbfgs presentó el mayor accuracy, precision, F1-score y ROC AUC.

El hiperparámetro con mayor influencia observable fue C. Al cambiar C de 0.01 a 0.1, dejando constantes el solver, las iteraciones, la tolerancia, la semilla y la partición, el recall aumentó de 0.8571 a 0.9524 y el F1-score de 0.9231 a 0.9756. El valor C=0.01, que representa una regularización más intensa, redujo la capacidad para identificar casos malignos. No obstante, aumentar C por encima de 0.1 tampoco generó mejoras consistentes. Con C=1.0 disminuyeron recall y F1-score, mientras que con C=10.0 el ROC AUC descendió a 0.9864.

La configuración con liblinear también obtuvo recall de 0.9524, pero modificó simultáneamente el solver, la tolerancia y el máximo de iteraciones. Por ello, no es posible atribuir su resultado exclusivamente al cambio de solver. Las corridas de reproducibilidad produjeron métricas idénticas al utilizar los mismos argumentos.

Las principales limitaciones son el tamaño reducido del dataset, el uso de una sola partición de entrenamiento y prueba, el rango limitado de hiperparámetros, la falta de validación cruzada y la evaluación de un solo algoritmo. Los resultados son adecuados como evidencia experimental académica, pero no constituyen una validación para uso clínico.

Corrida	C	Solver	Máx. iter.	Tol.	Accuracy	Precision	Recall	F1-score	ROC AUC
C001_lbfgs	0.01	lbfgs	1000	0.0001	0.9474	1.0000	0.8571	0.9231	0.9977
C01_lbfgs	**0.10**	**lbfgs**	**1000**	**0.0001**	**0.9825**	**1.0000**	**0.9524**	**0.9756**	**0.9977**
C1_lbfgs_baseline	1.00	lbfgs	1000	0.0001	0.9649	0.9750	0.9286	0.9512	0.9960
C10_lbfgs	10.00	lbfgs	1000	0.0001	0.9737	0.9756	0.9524	0.9639	0.9864
C1_liblinear	1.00	liblinear	1500	0.0010	0.9737	0.9756	0.9524	0.9639	0.9960

Todas las corridas utilizaron random_state=42, test_size=0.20, división estratificada, 455 observaciones de entrenamiento, 114 de prueba y 30 características predictoras. Se resalta la configuración seleccionada.

Evidencia de reproducibilidad

Corrida	Accuracy	Precision	Recall	F1-score	ROC AUC
reproducibility_A	0.964912	0.975000	0.928571	0.951220	0.996032
reproducibility_B	0.964912	0.975000	0.928571	0.951220	0.996032

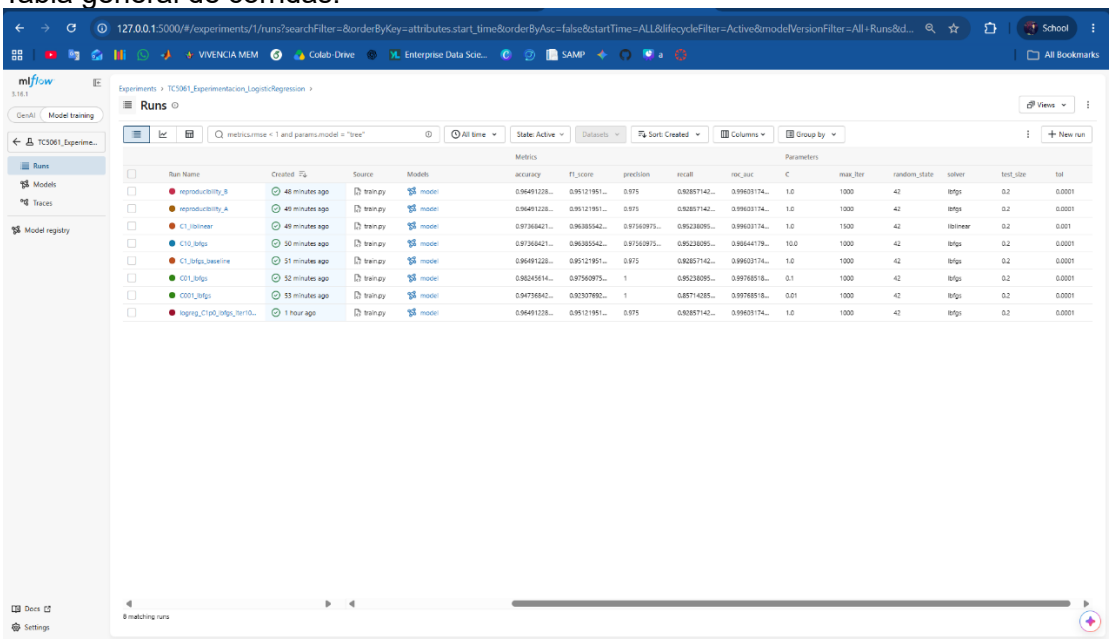
Las corridas reproducibility_A y reproducibility_B se ejecutaron con argumentos idénticos y generaron exactamente las mismas métricas, lo que confirma el comportamiento reproducible del flujo con la semilla 42 y las versiones declaradas en requirements.txt.

Anexos:

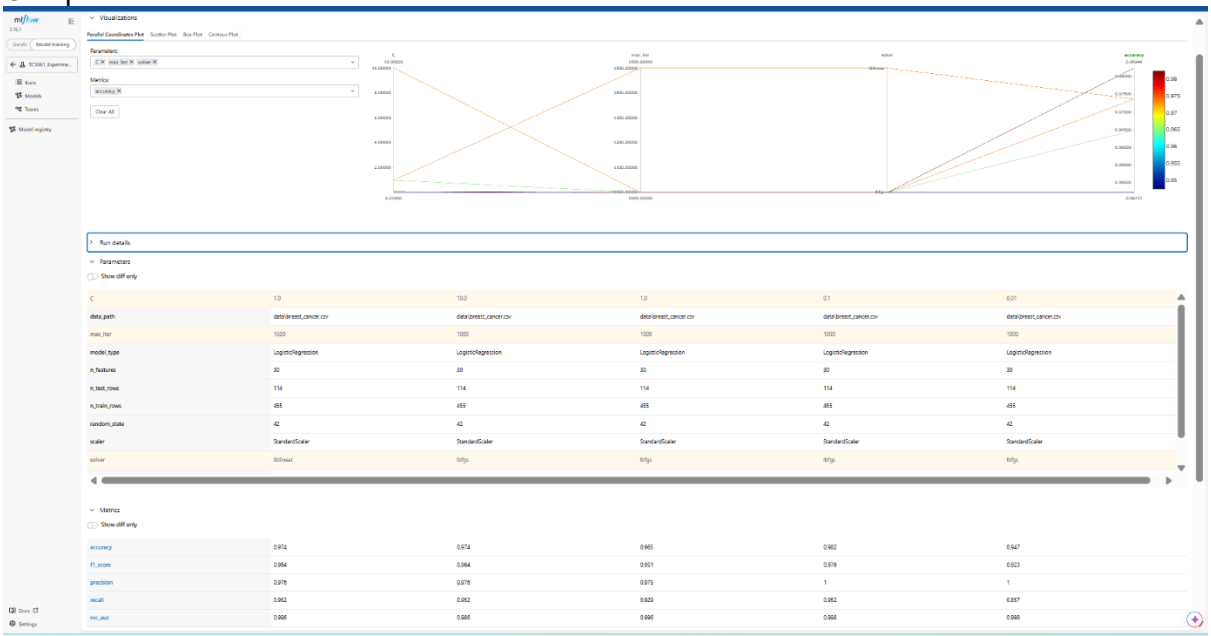
Evidencia de ejecución en MLflow, las cuales también se encuentran dentro del repositorio en la carpeta

. \evidence

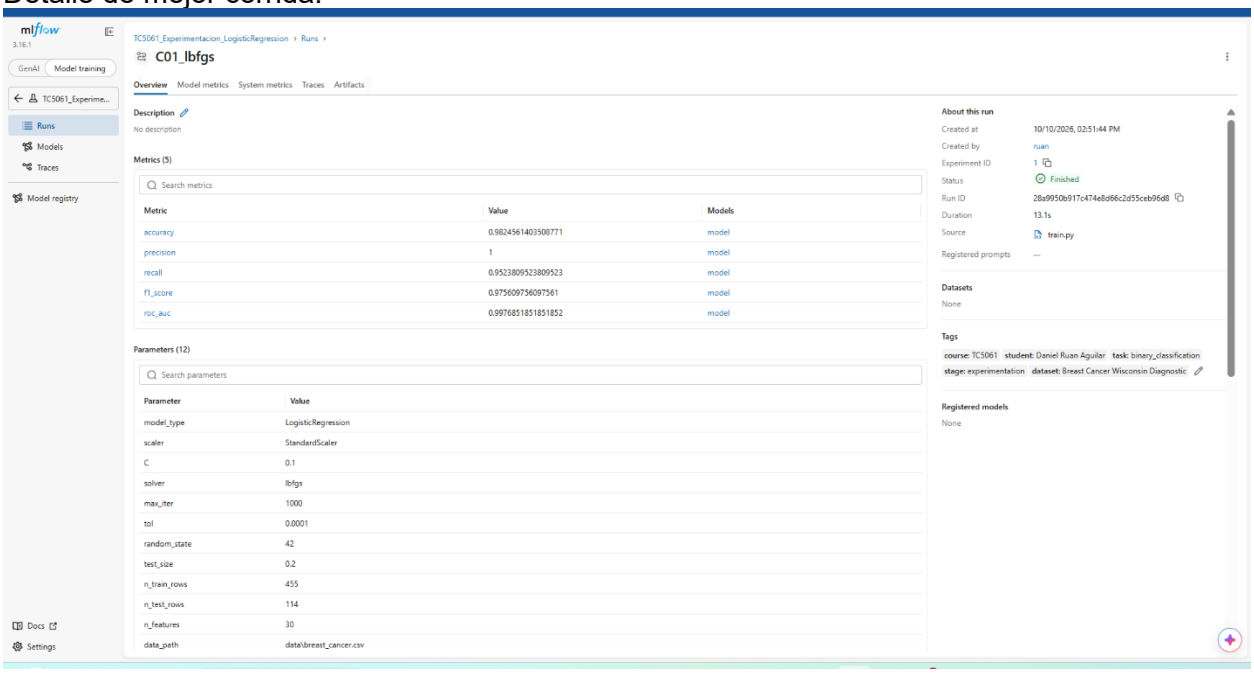
Tabla general de corridas:



Comparación:



Detalle de mejor corrida:



Artefactos de mejor corrida:

